Machine Learnin

Prof. Saulo Santos

01

Introdução ao Machine Learning

O que é Machine Learning?

É uma área da Inteligência Artificial (IA) que permite que computadores aprendam padrões a partir de dados e tomem decisões ou façam previsões sem serem explicitamente programados para cada tarefa.

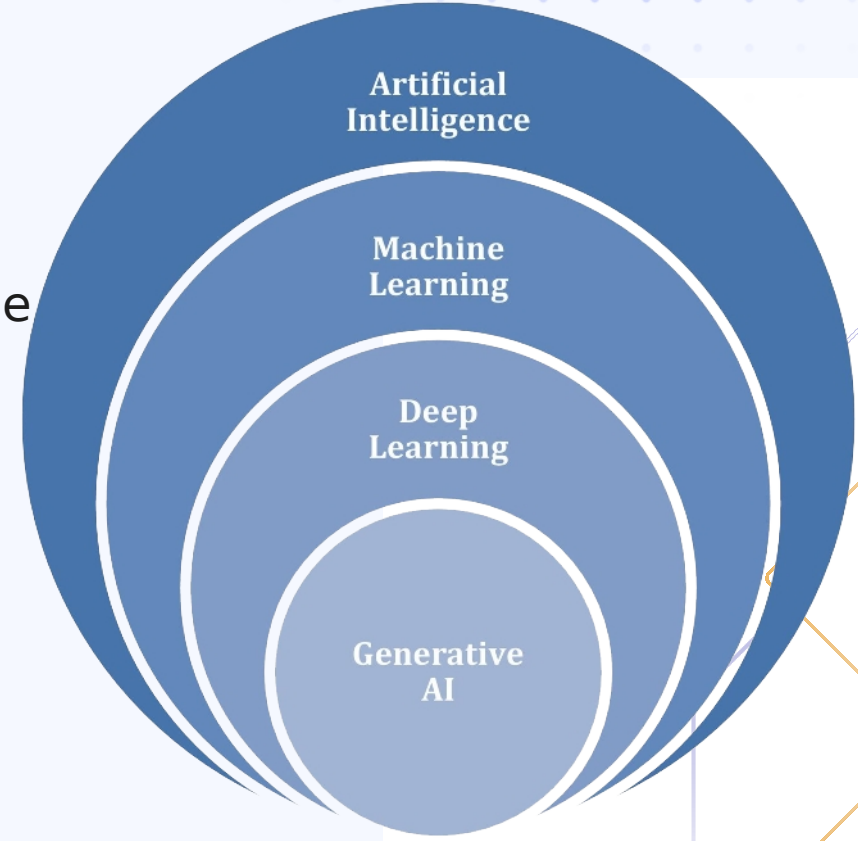

Aplicações do Machine Learning

Machine Learning está em muitos lugares do nosso dia a dia. Desde assistentes virtuais como a Siri, até recomendações personalizadas em plataformas de streaming. Também é usado na área de saúde para diagnóstico precoce, e no mercado financeiro para detectar fraudes. É uma tecnologia que está transformando diversos setores com sua capacidade de aprender e se adaptar.

Tipos de Machine Learning

Existem três tipos principais: **supervisionado**, onde o modelo aprende com dados rotulados; **não supervisionado**, que busca padrões em dados sem rótulos; e por **reforço**, onde o sistema aprende por tentativas e erros, recebendo recompensas para melhorar suas ações.

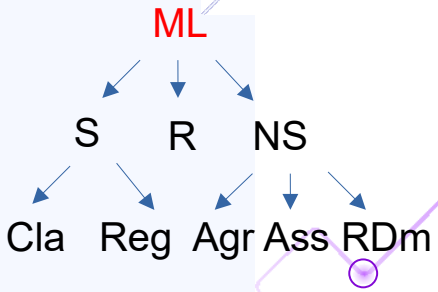

Aprendizado Supervisionado

No aprendizado **supervisionado**, a IA aprende por meio de exemplos previamente rotulados, ou seja, fazendo uso de dados que possuem a resposta de interesse. O modelo irá aprender a prever qual deveria ser a resposta em situações em que tal resposta não existe. Por exemplo, queremos classificar novas imagens tendo como base outras imagens que já estavam classificadas.

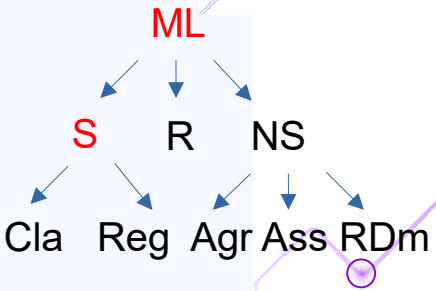

Aprendizado Supervisionado

Existem dois grandes tipos de problemas nesse contexto.

O **primeiro** chamamos de **classificação**. É quando queremos prever uma categoria (classe). Por exemplo inadimplente e adimplente, paciente doente e paciente saudável, documento confidencial e público.

A **classificação** responde: "*Qual categoria*" e fornece uma saída **discreta**, ou seja,ela só pode assumir valores de um conjunto finito ou enumerável.

Formalmente: $Y \in \{c_1, c_2, \ldots, c_k\}$, onde **c** representa categorias.

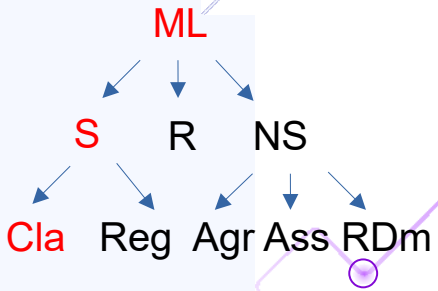

Aprendizado Supervisionado

Churn: $Y \in \{0,1\}$
Pergunta do modelo: Esse cliente vai sair ou não?
Classes:
0 = cliente permanece
1 = cliente cancela
Não existe "0.3 churn" Ou ele sai ou não sai.

Fraude: $Y \in \{fraude, normal\}$
Pergunta do modelo: Uma transação é fraude ou não é?
Não existe "R$ 200 de fraude".

Tipo de Produto: $Y \in \{eletrônico, roupa, alimento\}$
Pergunta do modelo: Qual a categoria do produto?
Não existe "celular, calça ou laranja".

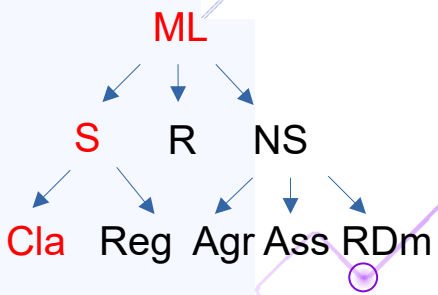

Aprendizado Supervisionado

O **segundo** caso chama-se **regressão**, quando a previsão envolve valores numéricos como preço de casas.

A regressão responde:"Quanto?". E fornece uma saída **contínua**, ou seja, ela só pode assumir infinitos valores dentro de um intervalo. Formalmente ela está dentro de um intervalo: $Y \in [a,b]$.

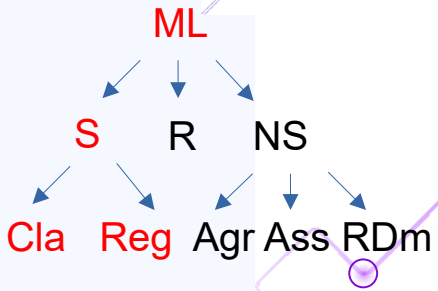

Aprendizado Supervisionado

Preço de imóvel: $Y \in R$
Pergunta do modelo: Quanto vale esse imóvel (valor numérico)?

Temperatura: $Y \in [a,b]$
Pergunta do modelo: Qual é a temperatura (valor numérico)?

Score de Crédito: $Y \in [a,b]$
Pergunta do modelo: Qual o score (valo numérico) de crédito?

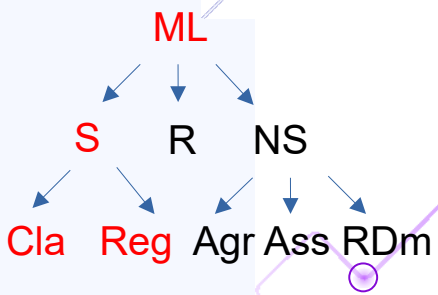

Aprendizado Supervisionado

Imagine que você tem uma base de dados com: Idade, Renda e Tempo de Serviço de 10000 clientes.

Se você deseja responder: "Essa pessoa terá inadimplência?",
então você tem um problema de **classificação**,
cuja saída será: $Y \in \{sim, não\}$

Se você deseja responder: "Qual será o valor da dívida dessa pessoa?"
então você tem um problema de **regressão**,
cuja saída será: $Y \in R$

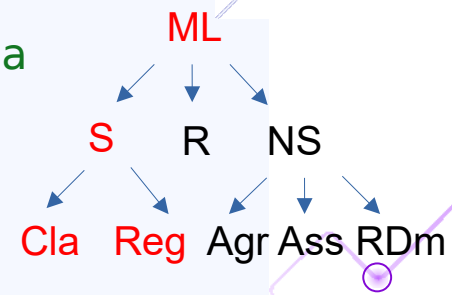

Aprendizado Supervisionado

Classificação resolve um problema de decisão categórica.

Regressão resolve um problema de estimativa numérica.

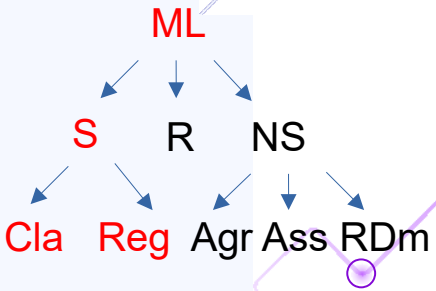

Aprendizado Não Supervisionado

E se, ao invés de mostrar as respostas para a IA, simplesmente entregássemos os dados e disséssemos: "**Descubra o que pode ser aprendido daqui**". Esse é o espírito do aprendizado **não supervisionado**. Aqui os dados não têm rótulos ou respostas certas.

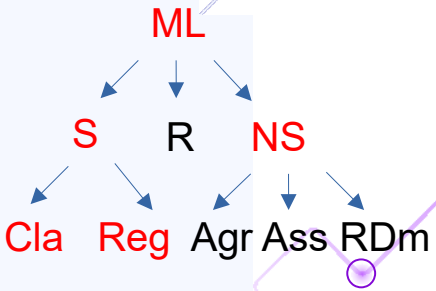

Aprendizado Não Supervisionado

A missão do algoritmo é buscar **estrutura**, identificar **padrões** e extrair **sentido** das informações disponíveis. Três possibilidades deste tipo de aprendizagem são:

- agrupamento

- associação

- redução de dimensão

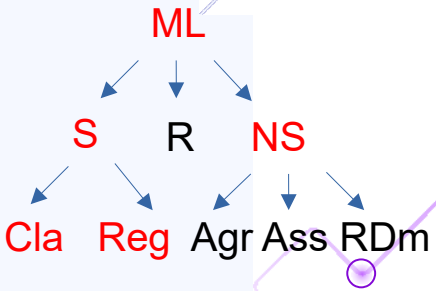

Aprendizado Não Supervisionado

Vamos falar primeiro do **agrupamento**, também conhecido como **clustering**. Aqui queremos **segmentar** os elementos analisados em **grupos**. No contexto de análise de clientes com base em comportamentos de compra, podemos, por exemplo, agrupar consumidores que adquirem itens de luxo e produtos exclusivos ou aqueles que consomem poucos produtos de baixo valor.

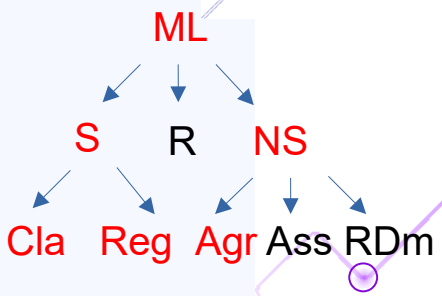

Aprendizado Não Supervisionado

Podemos também trabalhar com **associação**, usada para identificar padrões de coocorrência entre itens. Um exemplo clássico desse conceito está na análise de compras. Se um cliente adquire determinado produto, quais são os itens mais propensos a serem comprados juntos? Você sabia que já foi detectado que clientes do sexo masculino entre 25 e 35 anos compravam cerveja e fralda juntos?

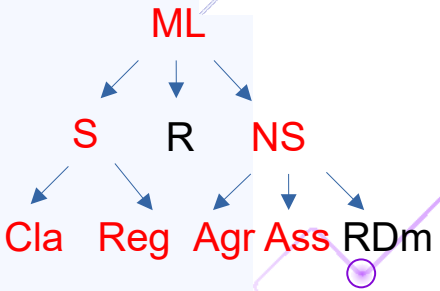

Aprendizado Não Supervisionado

A terceira abordagem é a **redução de dimensionalidade**, especialmente útil quando lidamos com bases de dados enormes, cheias de variáveis. Para simplificar, pense nas variáveis como colunas em uma planilha em Excel. Podemos começar com 100 colunas, e, ao final, ter apenas 4, preservando o que realmente importa. É como compactar uma foto. Reduz o tamanho, mas mantém o essencial visível.

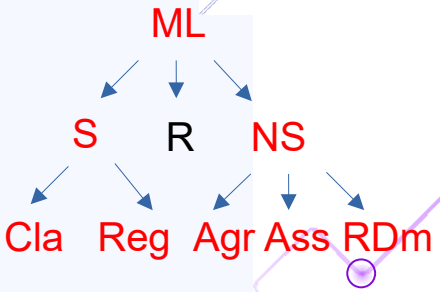

Aprendizado Não Supervisionado

Exemplos:

1. Segmentação de clientes de modo a criar grupos com comportamentos de compras similares.

2. Identificação transações suspeitas ao reconhecer padrões diferentes do habitual.

3. Criação de playlists com base em características como ritmo, melodia ou instrumentos.

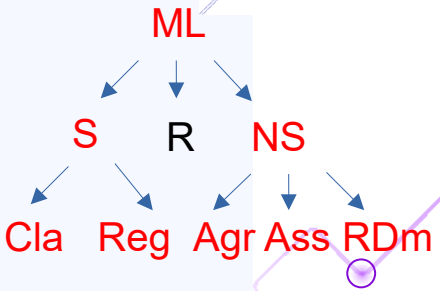

Aprendizado por Reforço

No aprendizado por **reforço**, a IA funciona por tentativa e erro, ajustando as decisões com base nos **feedbacks** recebidos.

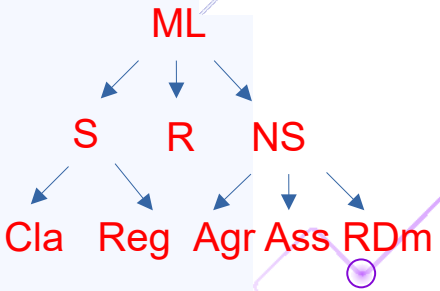

Aprendizado por Reforço

Exemplos:

1. IA em Jogos.

2. Navegação de Robôs.

3. Decisão em tempo real.

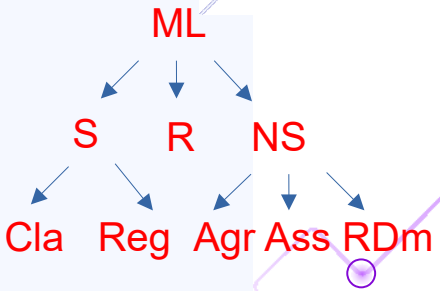

Aprendizado de Máquina
Aprendizado não Supervisionado
Redução Dimensional
Elicitação de Recursos
Descoberta de Estruturas
Compreensão Significativa
Visualização de Big Data
Clusterização
Sistemas de Recomendação
Alvo de Marketing
Segmentação de Clientes
Aprendizado Supervisionado
Classificação
Detecção de Fraudes
Classificação de Imagens
Retenção de Clientes
Diagnósticos
Regressão
Previsões
Predições
Otimização de Processos
Precificação
Aprendizado por Reforço
Decisão em tempo real
Navegação de Robôs
IA em jogos
Aprendizado de Tarefas
Aquisição de Habilidades

01

Como escolher o melhor algoritmo de Machine Learning?

Qual o melhor algoritmo?

O algoritmo perfeito existe? Se você espera uma resposta simples, prepare-se para a realidade. No machine learning, tudo **depende** do contexto do problema. A palavra **depende** é a resposta certa para quase todas as perguntas. Isso porque algoritmos são como ferramentas, e a escolha **depende** do objetivo que queremos alcançar, dos dados disponíveis e das restrições do problema. A **arte** está em escolher uma ferramenta que faça sentido para o seu cenário.

Qual o melhor algoritmo?

Podemos pensar em atributos como:

- **Escalabilidade**: Eu tenho dados limitados a um grande volume?

- **Desempenho**: Minha prioridade é obter respostas rápidas, ou eu posso focar na precisão do resultado analítico?

- **Recursos**: Qual é o custo computacional aceitável.

- **Interpretabilidade**: Preciso entender como a decisão foi tomada?

Interpretabilidade

Algoritmos mais simples, como **regressão linear**, **regressão logística** ou **árvore de decisão**, se destacam justamente pela transparência e facilidade de aplicação. Exigem menos dados e recursos computacionais, e possuem a vantagem de ser interpretáveis. Em áreas como saúde, finanças e direito, entender como a IA chegou a uma decisão pode ser tão importante quanto a precisão do resultado.

Interpretabilidade

Já em outros cenários existem modelos que nos distanciam da interpretabilidade, mas garantem maior precisão. É o caso das abordagens conhecidas como **Bagging** e **Boosting**, que trabalham com a combinação de diferentes algoritmos e estratégias.

Interpretabilidade

O exemplo mais conhecido é o **Random Forest**, que é uma técnica de **bagging**, que utiliza várias árvores de decisão para obter os seus resultados. Existem outros algoritmos famosos, como **XGBoost** e **Gradient Boosting**, que melhoram a precisão dos modelos ao corrigir os erros progressivamente. Inclusive, estes algoritmos são amplamente utilizados em competições de machine learning em sites como **Kaggle**, onde a otimização da precisão é o objetivo.

Interpretabilidade

Mas existem algoritmos ainda mais complexos, como as **redes neurais profundas**, que são capazes de modelar cenários extremamente desafiadores. Mas aqui, há a necessidade de encontrar um equilíbrio, pois quanto mais poderosa a IA, menos conseguimos entender o que ela decide, além de demandar mais dados, mais tempo de treinamento e poder computacional.

Interpretabilidade

Portanto, a questão não é **qual** algoritmo é o melhor, mas **qual** é o mais adequado para o problema que você deseja resolver. Em muitos casos, um modelo simples pode ser suficiente e tem a vantagem de ser interpretável, o que ajuda a desenharmos ações **data driven**.

Redes Neurais e Deep Learning

Inspiradas no cérebro humano, redes neurais são estruturas que processam dados em camadas, permitindo o aprendizado de tarefas complexas. Deep learning é uma evolução disso, com múltiplas camadas que capturam detalhes e padrões sutis em grandes volumes de dados, sendo fundamental em reconhecimento de imagem, voz e linguagem natural.

Deep Learning

O cérebro humano é, a máquina de aprendizado mais impressionante que conhecemos. Reconhece rostos, orquestra, manipulação de utensílios, toma decisões complexas e se adapta em questão de segundos. Tudo isso graças a uma verdadeira rede biológica. São mais de **80 bilhões de neurônios interligados** por algo em torno de um quatrilhão de sinapses.

Deep Learning

Vamos pensar nos neurônios como uma equipe em que cada um é responsável por uma micro decisão. Imagine que você percebe: Faltam 10 minutos para a próxima reunião. Imediatamente, neurônios diferentes começam a reagir:

Um pondera: Quão longe eu estou da sala?
Outro questiona: Será que dá tempo de pegar um café?
Um terceiro lembra: Se eu atrasar, será que terei onde sentar?

Deep Learning

As sinapses que conectam os neurônios funcionam como um comitê onde cada conexão dá o seu voto sobre a ação a ser tomada.

Quanto mais você repete uma decisão, mais forte fica essa conexão. Ou seja, as sinapses envolvidas no processo são reforçadas ao longo do tempo.

Deep Learning

A concepção das redes neurais artificiais se inspira diretamente no funcionamento do cérebro humano, assim como os nossos neurônios biológicos **recebem**, **processam** e **transmitem** sinais, os neurônios artificiais recebem dados, identificam padrões e ajustam suas conexões para aprimorar a saída do sistema.

Deep Learning

E é quando conectamos vários desses neurônios artificiais que formamos uma rede neural artificial. Visualmente, podemos imaginar essa rede como uma malha de pontos interconectados, onde cada um processa as informações recebidas e passa o resultado adiante.

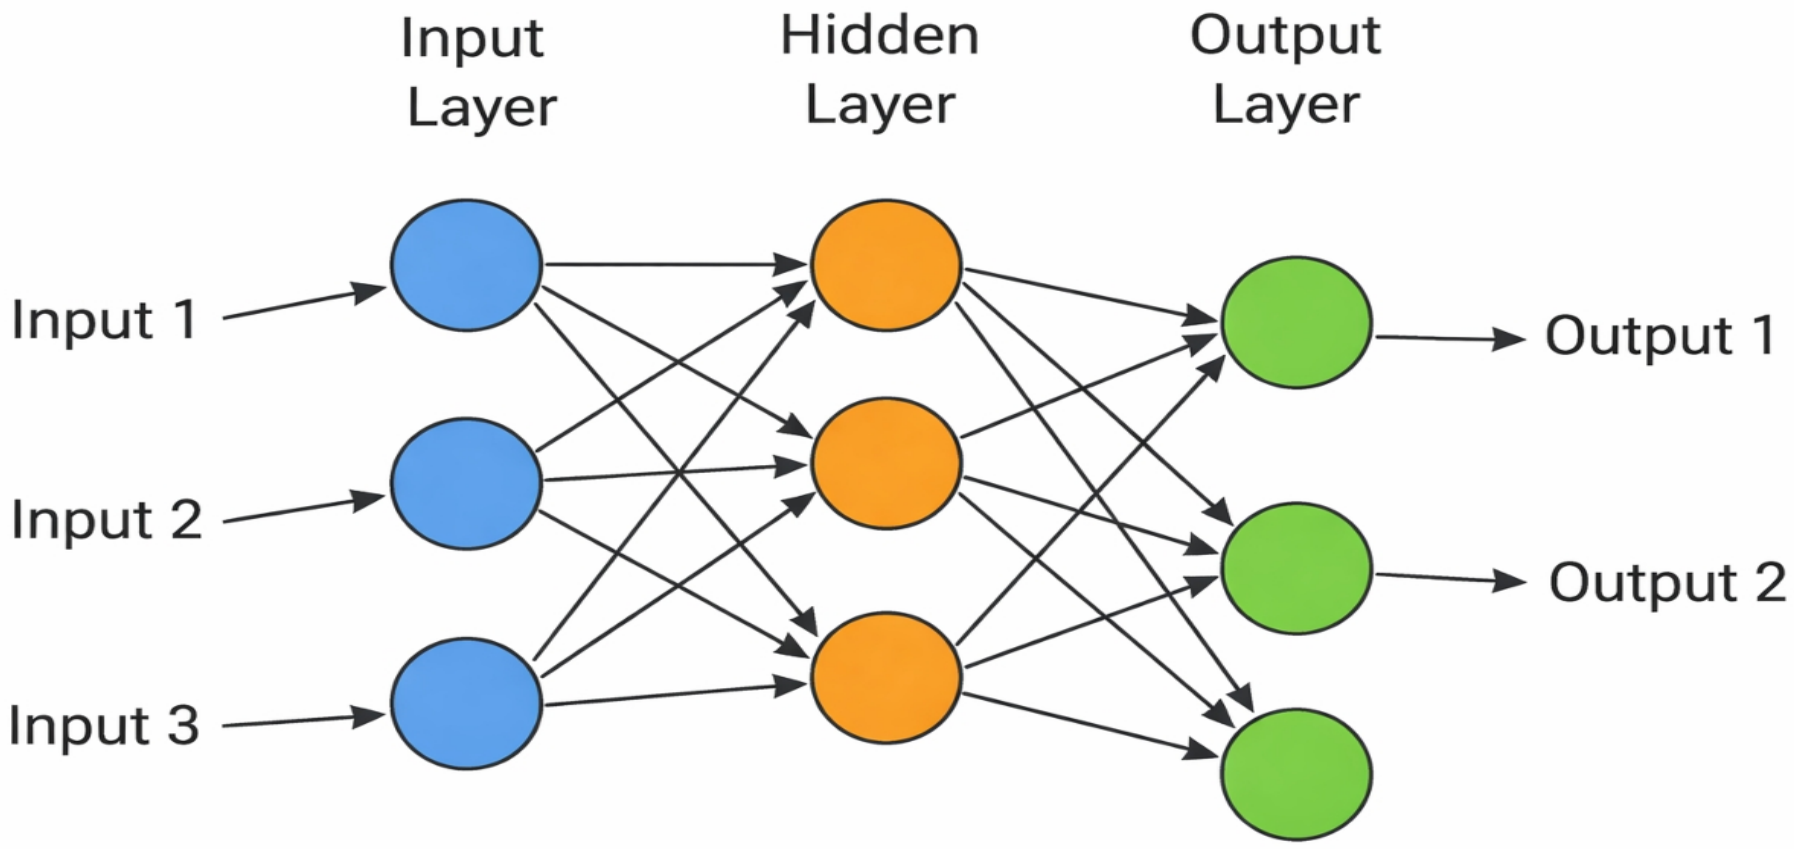
Input Layer
Hidden Layer
Output Layer
Input 1
Input 2
Input 3
Output 1
Output 2

Deep Learning

Ao processar a imagem de um cachorro, as primeiras camadas da rede podem identificar bordas e cores. Depois, as camadas intermediárias combinam essas informações para detectar formas e texturas, como o contorno das orelhas ou o formato do focinho. Por fim, as últimas camadas integram todos esses dados para reconhecer a imagem como um cachorro.

Deep Learning

Dependendo da complexidade do problema, pode ser necessário um maior número de camadas intermediárias para capturar características mais detalhadas e garantir classificações mais precisas. Ou seja, quanto mais profunda a rede, mais sofisticados são os padrões que ela consegue captar.

Dados Não Estruturados

A habilidade do deep learning de lidar com padrões extremamente complexos permitiu que ele se tornasse uma das principais ferramentas para lidar com o tipo de dados que até então estava sendo subutilizado, os dados **não estruturados**.

Você já se perguntou como uma IA consegue entender uma imagem ou interpretar um texto?

Dados Não Estruturados

Diferentemente das tradicionais tabelas com linhas e colunas, que chamamos de **dados estruturados**, esses não seguem um formato rígido.

Agora pense em uma foto , vídeo, áudio ou uma sequência de mensagens textuais. Esses são dados não estruturados, ricos em informação, mas complexos de um ponto de vista de processamento. Estima-se que mais de 90% sejam **dados não estruturados**.

Dados Não Estruturados

As máquinas não processam imagem ou texto diretamente como nós. Elas pensam em números. Portanto, precisamos traduzir os dados não estruturados em valores numéricos. Por exemplo, imagens são representadas como **pixels**, onde cada número define **cor** e **luminosidade**. Os áudios são convertidos em espectrogramas, mapas visuais das ondas sonoras. Os textos, por sua vez, tornam-se vetores numéricos que codificam a relação semântica entre as palavras. Esse processo de conversão é apenas a primeira etapa.

Dados Não Estruturados

Precisamos também adaptar as redes para que processem essas informações de maneira coerente com a natureza dos dados, adaptando **função de ativação** ou definindo a estrutura das **camadas ocultas**. E é aqui que entram as arquiteturas especializadas de redes neurais. Temos, por exemplo, **redes neurais convolucionais**, ideais para o processamento de **imagens** e **vídeos** e as **redes neurais recorrentes** voltadas para **dados sequenciais**, como textos ou séries temporais.

Deep Learning: aplicações

Se até aqui exploramos os bastidores dos sistemas de IA, agora é hora de ver na prática como o **deep learning** está transformando nossas vidas, muitas vezes de formas tão sutis que nem nos damos conta. Desde a sugestão do próximo vídeo no YouTube até a detecção precoce de doenças em exames de imagem, o princípio por trás de tudo isso é o mesmo, redes neurais profundas processando dados, aprendendo padrões e tomando decisões com base neles.

Deep Learning: aplicações

Vamos explorar algumas das áreas onde o deep learning já faz parte da nossa rotina com a IA aprendendo a ver, falar e escrever. A visão computacional é a área da inteligência artificial dedicada a ensinar máquinas, a interpretar imagens e vídeos. O objetivo parece simples, mas é extremamente desafiador fazer com que os sistemas não apenas vejam, mas também compreendam o mundo visual. Hoje já temos algumas aplicações.

Deep Learning: aplicações

Reconhecimento facial, com celulares e câmeras de segurança, permitindo desbloqueio de dispositivos, autenticação em aplicativos e monitoramento inteligente em espaços públicos. Temos também diagnóstico de doenças a partir de exames médicos, como radiografias ou tomografias, identificando lesões e tumores com alta precisão. Graças ao deep learning, as máquinas não só identificam objetos, mas são capazes de entender o seu contexto.

Deep Learning: aplicações

Diferenciar, por exemplo, uma bola parada de uma bola em movimento, ou diagnosticar um paciente com base na combinação de histórico médico, exames e até mesmo DNA. Uma outra área revolucionada pelo deep learning é a análise de áudio e reconhecimento de voz. Aqui o desafio é fazer com que as máquinas compreendam não apenas os sons, mas também as nuances da fala humana.

Deep Learning: aplicações

Entre as aplicações podemos destacar ferramentas de transcrição automática que convertem fala em texto, assistente de voz, como Alexa, Google Assistant ou a Siri, sistemas de atendimento automatizado que reconhecem perguntas e oferecem respostas por telefone. Evoluímos a um ponto em que a interação com as máquinas acontece de forma cada vez mais natural. Alguns sistemas modernos já conseguem captar emoções na fala, analisando variações de tom e ritmo para oferecer interações mais humanas.

Deep Learning: aplicações

Por fim, temos a área que ensina as máquinas a compreender e gerar a linguagem humana. Mais do que traduzir palavras, o desafio é interpretar o contexto, a intenção e o significado. Entre as aplicações mais comuns estão chatbots inteligentes, tradutores automáticos e sistemas de correção e sugestão para e-mails, mensagens e documentos. O avanço do deep learning permitiu que esses sistemas deixassem de ser simples respostas pré-programadas para textos mais naturais e contextuais. Um passo essencial para que as IA conversacionais que vemos hoje.

Deep Learning: aplicações

Ao combinarmos sistemas que lidam com diferentes tipos de dados, temos aplicações ainda mais interessantes, como os carros autônomos que combinam imagens de câmera, sinais de sensores e mapas para tomar decisões instantaneamente, plataformas de saúde que cruzam exames de imagem, históricos médicos e dados de sensores vestíveis para apoiar diagnósticos ou ainda sistemas antifraude que analisam simultaneamente textos de e-mail, padrões de comportamento financeiro e dados de navegação.

Deep Learning: aplicações

E ainda há muito a ser explorado, especialmente com o avanço de novas fronteiras, como a inteligência artificial generativa. Modelos recentes voltados para o processamento de textos vêm possibilitando soluções inovadoras, como o ChatGPT. No próximo capítulo vamos mergulhar nessas possibilidades e entender como essas tecnologias estão transformando a forma como interagimos com as máquinas.

Conclusões

Machine Learning é uma ferramenta poderosa que está mudando o mundo em que vivemos. Com suas técnicas diversas e aplicações amplas, oferece soluções inteligentes para problemas reais. Entender seus fundamentos e potencial é essencial para tirar o máximo proveito dessa tecnologia que continua a evoluir e impactar nosso dia a dia.

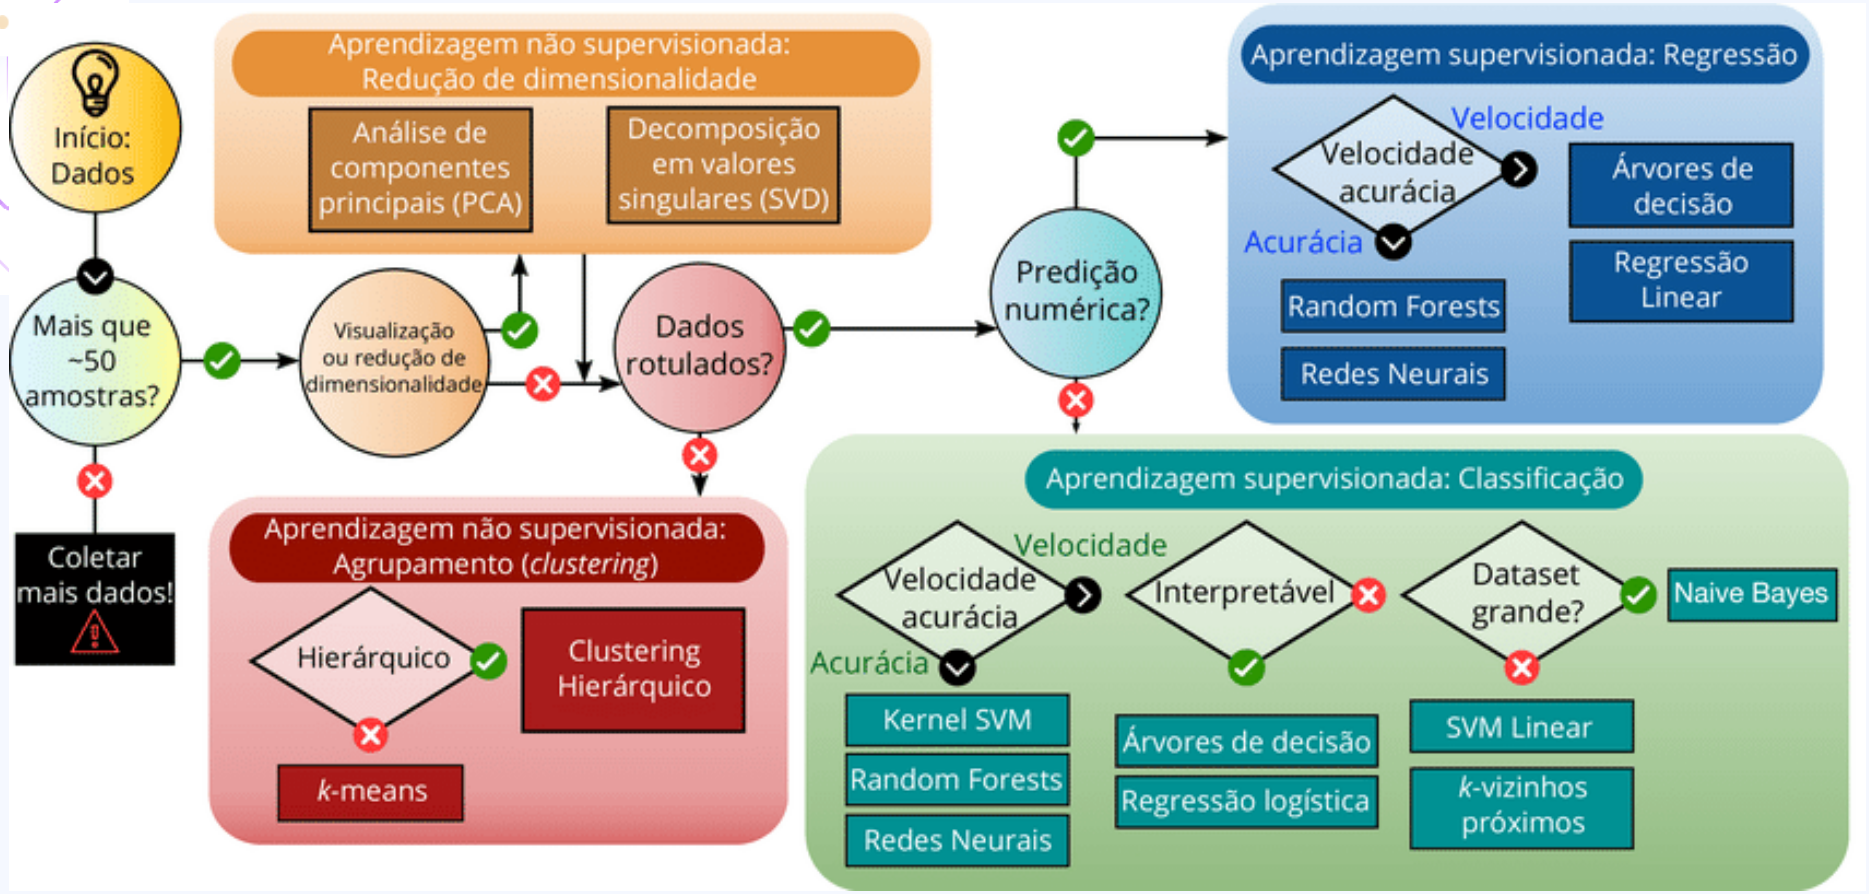
Início: Dados
Mais que ~50 amostras?
Coletar mais dados!
Visualização ou redução de dimensionalidade
Aprendizagem não supervisionada: Redução de dimensionalidade
Análise de componentes principais (PCA)
Decomposição em valores singulares (SVD)
Dados rotulados?
Predição numérica?
Aprendizagem supervisionada: Regressão
Velocidade
Velocidade acurácia
Acurácia
Árvores de decisão
Regressão Linear
Random Forests
Redes Neurais
Aprendizagem não supervisionada: Agrupamento (clustering)
Hierárquico
Clustering Hierárquico
k-means
Aprendizagem supervisionada: Classificação
Velocidade
Velocidade acurácia
Acurácia
Interpretável
Dataset grande?
Naive Bayes
Kernel SVM
Random Forests
Redes Neurais
Árvores de decisão
Regressão logística
SVM Linear
k-vizinhos próximos

Etapas de funcionamento do Machine Learning